Hochschule Wismar

„Leitlinien für große Sprachmodelle zur automatisierten Fragebogenerstellung: Ein Design-Science-Ansatz am Beispiel der KI-Readiness von Krankenhauspersonal“

Praxisseminar / Hausarbeit

vorgelegt an der Fakultät für Wirtschaftswissenschaft
der Hochschule Wismar

eingereicht von:	Niklas Hähnlein
	geboren am 19.09.1995 in Preetz
	Master CMP
	Matrikelnummer: 585653
Modulverantwortlicher:	Prof. Dr. H. Sturm
Betreuer:	Dr. Johannes Wichmann
Abgabe am:	30.10.2026

Inhaltsverzeichnis

Abbildungsverzeichnis ..... **II**

Tabellenverzeichnis ..... **III**

Abkürzungsverzeichnis ..... **IV**

1 Einleitung **1**

1.1 Problemstellung 1

1.2 Ziel und Fragestellung der Arbeit 2

1.3 Aufbau der Arbeit 2

2 Entwicklung der Leitlinien nach dem Design-Science-Research-Prozess **3**

2.1 Methodisches Vorgehen 3

2.2 Problemidentifikation und Ziele der Lösung 4

2.3 Iteration 0: Fragebogenerstellung ohne Leitlinien 5

2.4 Iteration 1: Inhaltliche Führung im Dialog 6

2.5 Iteration 2: Gezielte Korrekturen im Dialog 7

2.6 Iteration 3: Masterprompt 8

2.6.1 Entstehung und Demonstration 8

2.6.2 Evaluation 8

2.7 Kommunikation 9

3 Fazit **11**

3.1 Beantwortung der Forschungsfrage 11

3.2 Limitationen und Ausblick 11

Literaturverzeichnis ..... **XIII**

Anhang A ..... **XVII**

A.1 Masterprompt mit Prüfliste XVII

A.2 Prüfliste für die abschließende Prüfung durch einen Menschen XIX

Anhang B ..... **XX**

B.1 Wissensbasis XX

B.2 Iterationsprotokoll - Nachrichtenverlauf XXI

B.3 Vollständiger Chatverlauf des Entwicklungsnotebooks XXIII

Anhang C ..... **XXIV**

C.1 Chatverläufe der finalen Durchläufe XXIV

Anhang D ..... **XXV**

D.1 Ziele und Anforderungen XXV

Ehrenwörtliche Erklärung ..... **XXIX**

Abbildungsverzeichnis

Abb. 1: Iterativer DSR-Prozess dieser Arbeit (eigene Darstellung, erstellt mit Claude Opus 5.5, in Anlehnung an Peffers et al., 2007)..... 3

Tabellenverzeichnis

Tab. 1: Ziele und Anforderungen an die Leitlinien XXVII
Tab. 2: Zielerreichung über alle Iterationen (eigene Darstellung) XXVIII

Abkürzungsverzeichnis

DSR - Design Science Research

FEDS - Framework for Evaluation in Design Science Research

KI - Künstliche Intelligenz

LLM - Large Language Model (großes Sprachmodell)

MAIRS-MS - Medical Artificial Intelligence Readiness Scale for Medical Students

UTAUT - Unified Theory of Acceptance and Use of Technology

UTAUT2 - Unified Theory of Acceptance and Use of Technology 2

TRI 2.0 - Technology Readiness Index 2.0

1 Einleitung

1.1 Problemstellung

Ob Künstliche Intelligenz (KI) in der Gesundheitsversorgung tatsächlich einen Nutzen stiftet, hängt nicht allein von der Technik ab. Ebenso entscheidend sind das Wissen der Beschäftigten über KI, ihre Fähigkeiten im Umgang damit und ihre Einstellung gegenüber der Technik. Diese Voraussetzungen werden unter dem Begriff medical artificial intelligence readiness zusammengefasst (Karaca et al., 2021, S. 2), im Folgenden kurz „KI-Readiness“. Im Krankenhaus spielt sie eine besondere Rolle, da KI im Arbeitsalltag von medizinischem Personal immer weiter Einzug hält. Hier wird KI vor allem in der bildgebenden Diagnostik eingesetzt, etwa um Auffälligkeiten in radiologischen Aufnahmen zu markieren (Antweiler et al., 2026). Weitere Einsatzfelder sind die klinische Entscheidungsunterstützung, die Arzneimitteltherapiesicherheit und die Spracherkennung beim ärztlichen Diktat (Antweiler et al., 2024). Dabei verlässt sich das Personal auf Informationen, die auch falsch sein können. Wie folgenreich dies ist, zeigt eine Studie von Jussupow et al. (2021), in der selbst erfahrene Radiologinnen und Radiologen ungenauere Diagnosen stellten, da sie fehlerhafte KI-Empfehlungen nicht kritisch genug prüften. Zugleich stehen Krankenhäuser unter dem Druck von Fachkräftemangel und wachsendem Dokumentationsaufwand (Antweiler et al., 2026). Folglich sollten Krankenhäuser die KI-Readiness ihres Personals bereits vor der Einführung von KI kennen, um den Qualifizierungsbedarf trotz knapper Ressourcen gezielt angehen zu können (Antweiler et al., 2024). Erfassen lässt sich die KI-Readiness mit Fragebögen, die Wissen, Fähigkeiten und Einstellungen messen. Die Entwicklung solcher Fragebögen gilt jedoch als anspruchsvoll, da Konstrukte klar definiert, passende Fragen formuliert und deren Validität belegt werden müssen (MacKenzie et al., 2011). Bestehende Messinstrumente zur KI-Readiness sind zudem jeweils auf eine bestimmte Zielgruppe und einen bestimmten Kontext zugeschnitten. So richtet sich die Medical Artificial Intelligence Readiness Scale for Medical Students (MAIRS-MS) an Medizinstudierende (Karaca et al., 2021). Eine neuere Skala erfasst dagegen die KI-Kompetenz von Gesundheitspersonal in Singapur (Ang et al., 2026). Ansätze für Krankenhäuser wiederum betrachten meist die Bereitschaft der Organisation als Ganzes (Antweiler et al., 2026; Weinert et al., 2022). Für jede neue Zielgruppe muss ein passendes Instrument daher aufwendig angepasst oder neu entwickelt werden. Große Sprachmodelle (Large Language Models, LLMs) bieten hier einen Lösungsansatz, da sie Fragen automatisch generieren und so den Aufwand der Fragebogenentwicklung verringern (Hernandez & Nie, 2023). Ohne geeignete Datengrundlage liefern sie jedoch mitunter unvollständige, fehlerhafte oder sogar erfundene

Inhalte (Do Khac et al., 2025; Susarla et al., 2023). Leitlinien, die LLMs bei der Fragebogenentwicklung im klinischen Bereich gezielt steuern, fanden sich in der gesichteten Literatur kaum. Hier setzt die vorliegende Arbeit an.

1.2 Ziel und Fragestellung der Arbeit

Ziel dieser Arbeit ist die Entwicklung eines Artefakts im Sinne von Peffers et al. (2007). Dabei handelt es sich um Leitlinien für große Sprachmodelle, die als Masterprompt in NotebookLM (Stand Oktober 2026) umgesetzt werden. Ein Masterprompt ist hier eine vollständige Anweisung, nach der ein LLM ohne weitere Hinweise aus beispielhaften Fragebögen und kontextspezifischen Fachquellen einen Fragebogen erstellt. Die zugrunde liegende Theorie soll das LLM dabei selbst aus den Quellen ableiten und begründen. Daraus ergibt sich folgende Forschungsfrage: Wie müssen Leitlinien für große Sprachmodelle gestaltet sein, damit diese automatisiert theoretisch fundierte und praxisnahe Fragebögen erstellen können? Als theoretisch fundiert gilt ein Fragebogen, wenn er auf einer begründet gewählten Theorie beruht, definierte Konstrukte misst und sich auf belegbare Quellen stützt. Als praxisnah gilt er, wenn auch Beschäftigte ohne KI-Vorwissen die Fragen verstehen und der Fragebogen zur Befragung vor der Einführung von KI passt. Kapitel 2.2 übersetzt beides in sechs Ziele, die auch Formulierung und Antwortformat abdecken. Demonstriert und evaluiert werden die Leitlinien am Beispiel der KI-Readiness von Krankenhauspersonal. Bereitgestellt werden sie über GitHub.

1.3 Aufbau der Arbeit

Der Aufbau folgt dem Design-Science-Research-Prozess. Nach dem methodischen Vorgehen (Kapitel 2.1) stellt Kapitel 2.2 Forschungsstand und Theorie vor und leitet sechs Ziele ab. Die Kapitel 2.3 bis 2.6 zeichnen vier Iterationen bis zum finalen Masterprompt und seiner Evaluation nach. Kapitel 2.7 beschreibt die Bereitstellung über GitHub. Kapitel 3 beantwortet die Forschungsfrage, nennt Limitationen und gibt einen Ausblick.

2 Entwicklung der Leitlinien nach dem Design-Science-Research-Prozess

2.1 Methodisches Vorgehen

Methodisch folgt die Arbeit dem Design-Science-Research-Prozess (DSR-Prozess) nach Peffers et al. (2007), der auf die Entwicklung und Evaluation von Artefakten zur Lösung praktischer Probleme ausgerichtet ist. Der Prozess gliedert sich in sechs Aktivitäten: Problemidentifikation und Motivation, Definition der Ziele einer Lösung, Design und Entwicklung, Demonstration, Evaluation sowie Kommunikation. Die Aktivitäten sind zwar in einer festen Reihenfolge dargestellt, müssen aber nicht streng nacheinander durchlaufen werden. Deckt die Evaluation Defizite auf, kehrt der Prozess zu Design und Entwicklung zurück. Als Artefakte kommen Konstrukte, Modelle, Methoden oder Instanziierungen in Betracht (Peffers et al., 2007). Die in Kapitel 1.2 beschriebenen Leitlinien legen ein Vorgehen zur Erstellung von Fragebögen fest und sind daher dem Artefakttyp der Methode zuzuordnen; der Masterprompt bildet ihre Instanziierung. Da die Arbeit von dem in Kapitel 1.1 dargelegten Praxisproblem ausgeht, wählt sie einen problemzentrierten Einstieg (problem-centered initiation). Dass sich das Prozessmodell auf Gestaltungsprobleme im klinischen Umfeld übertragen lässt, zeigen Wichmann, Paetow, et al. (2024), die auf diesem Weg Designkriterien für Indoor-Positioning-Systeme ableiten. Abbildung 1 veranschaulicht den Forschungsablauf.

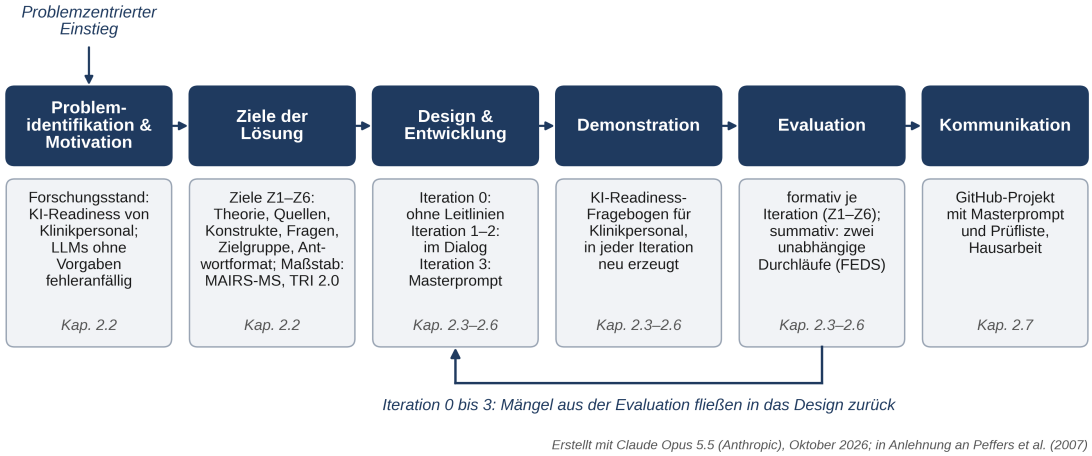


Abb. 1: Iterativer DSR-Prozess dieser Arbeit (eigene Darstellung, erstellt mit Claude Opus 5.5, in Anlehnung an Peffers et al., 2007)

Jede Iteration durchläuft die Aktivitäten Design und Entwicklung, Demonstration sowie Evaluation. In der Designphase werden die Vorgaben für das Sprachmodell angepasst, etwa die hinterlegte Wissensbasis oder die Anweisungen. Auf dieser Grundlage generiert NotebookLM in der Demonstration einen Fragebogen. Die Evaluation

misst ihn stets an denselben sechs Zielen aus Kapitel 2.2, wodurch Fortschritte über die Iterationen hinweg vergleichbar werden. NotebookLM eignet sich für dieses Vorgehen, da es seine Antworten auf die bereitgestellten Quellen stützt und die herangezogenen Textstellen als Belege ausweist. Konzeptionell entspricht dies der Retrieval-Augmented Generation (RAG), bei der ein Sprachmodell vor der Antwortgenerierung relevante Passagen aus einer externen Wissensbasis abruft und in seine Ausgabe einbezieht (Lewis et al., 2020). Die Evaluation orientiert sich am Framework for Evaluation in Design Science Research (FEDS). Es unterscheidet Evaluationen nach ihrem Zweck in formative und summative sowie nach ihrem Paradigma in artifizielle und naturalistische (Venable et al., 2016). Die Bewertungen in den Iterationen sind formativ, da sie Hinweise zur Verbesserung des Artefakts liefern. Die Bewertung des finalen Artefakts ist dagegen summativ und prüft, wie gut es die sechs Ziele erfüllt. Sprachmodelle können auf dieselbe Eingabe unterschiedlich antworten (Ouyang et al., 2025). Um die Stabilität der Ergebnisse zu prüfen, wird der Masterprompt deshalb in zwei unabhängigen Durchläufen ausgeführt und bewertet. Da alle Bewertungen anhand der sechs Ziele und ohne reale Befragung erfolgen, ist die Evaluation durchgehend artifiziell. Das Vorgehen entspricht damit weitgehend der Strategie „Technical Risk & Efficacy“, bei der ein Artefakt zunächst artifiziell und erst zum Schluss im realen Einsatz evaluiert wird (Venable et al., 2016). Dieser letzte Schritt geht über den Rahmen der vorliegenden Arbeit hinaus. Prompts und Modellantworten sind in den Anhängen B und C dokumentiert. Die Chatverläufe hat NotebookLM selbst exportiert. Einzelne Nachrichten sind dabei nur gekürzt erhalten (Anhang B.3).

2.2 Problemidentifikation und Ziele der Lösung

Während Kapitel 1.1 das Problem aus Sicht der Praxis beschreibt, betrachtet dieses Kapitel den Forschungsstand und leitet daraus die Ziele der Lösung ab. Die Forschung zur Haltung von Krankenhauspersonal gegenüber KI ist bislang vor allem Akzeptanzforschung. Laut einem integrativen Review von 42 Studien hemmt die Angst vor dem Verlust fachlicher Autonomie die Akzeptanz, Schulungen fördern sie dagegen (Lambert et al., 2023). Ärztinnen und Ärzte an deutschen Universitätskliniken stehen KI überwiegend positiv gegenüber (Maassen et al., 2021). Auch unter Pflegekräften in Bayern sehen zwei Drittel KI als Chance, doch nur ein Viertel verfügt über Expertenwissen (Sommer et al., 2024). Eine positive Einstellung allein reicht für einen kompetenten Umgang mit KI demnach nicht aus. Nur wenige der gesichteten Instrumente erfassen neben Einstellungen auch Wissen und Fähigkeiten von Klinikpersonal in Deutschland. Theoretischer Bezugspunkt ist das eingangs eingeführte Verständnis von KI-Readiness als Wissen, Fähigkeiten und Einstellungen (Karaca et al.,

2021, S. 2). Wissen und Fähigkeiten erfasst die MAIRS-MS in den vier Dimensionen Kognition, Fähigkeit, Vision und Ethik (Karaca et al., 2021). Zur Dimension Vision gehört etwa die Fähigkeit, Grenzen, Stärken und Schwächen von KI zu erklären. Damit greift diese Dimension den kritischen Umgang mit KI auf, dessen Fehlen Jussupow et al. (2021) als Fehlerquelle identifizieren. Die Einstellungen erfasst der Technology Readiness Index 2.0 (TRI 2.0): Optimismus und Innovationsfreude erhöhen die Bereitschaft, neue Technologien zu nutzen; Unbehagen und Unsicherheit senken sie (Parasuraman & Colby, 2015). Abzugrenzen ist KI-Readiness von Akzeptanz. Akzeptanzmodelle wie die Unified Theory of Acceptance and Use of Technology (UTAUT) erklären, warum Menschen ein bestimmtes System nutzen (Venkatesh et al., 2003). Wichmann, Gesk, et al. (2024) nutzen deren Weiterentwicklung UTAUT2 etwa in einem integrierten Modell für KI-gestützte Gesundheitsinformationssysteme aus Sicht von Patientinnen und Patienten. KI-Readiness ist dagegen nicht an ein bestimmtes System gebunden. Da das LLM die Theorie selbst vorschlagen soll, dienen MAIRS-MS und TRI 2.0 nicht als Vorgabe in den Leitlinien, sondern als Referenz für die Bewertung der Theoriewahl. Aus Problem und Theorie ergeben sich sechs Ziele, an denen jede Version der Leitlinien gemessen wird: Theoriebezug (Z1), belegbare Quellen (Z2), definierte Konstrukte (Z3), korrekt formulierte Fragen (Z4), Zielgruppe und Kontext (Z5) sowie Antwortformat (Z6). Anhang D zeigt die Anforderungen und die Herleitung der Ziele.

2.3 Iteration 0: Fragebogenerstellung ohne Leitlinien

Ausgangspunkt und Vergleichsbasis der Entwicklung ist ein Fragebogen, den NotebookLM ohne Leitlinien erstellte. Im Design dieser Iteration erhielt das Modell ausschließlich den Datensatz mit fünf Beispielfragebögen und den Auftrag: „Erstelle einen Fragebogen zur Messung der KI-Readiness von Krankenhauspersonal.“ In der Demonstration entstand ein Fragebogen mit sechs Dimensionen und 15 Fragen auf einer siebenstufigen Skala (Anhang B.3). Die Evaluation anhand der sechs Ziele zeigte grundlegende Mängel. Der Fragebogen nannte weder eine Theorie noch Quellen (Z1, Z2). Seine Dimensionen waren nur benannt, nicht definiert (Z3). Elf von 15 Fragen bündelten mehrere Aussagen, etwa „Ich beabsichtige und plane …“. Einzelne enthielten zudem wertende Begriffe wie „wertvolle Unterstützung“ (Z4). Mehrere Fragen übernahm das Modell nahezu wörtlich aus den Beispielfragebögen und formulierte sie lediglich auf KI um, etwa aus einem Fragebogen zu virtueller Realität oder aus Patientensicht (Z5). Bei den Angaben zur Person fehlte die Option „Sonstige“. Außerdem vermischte die Frage zur KI-Vorerfahrung Wissen und Nutzung (Z6). Das Modell nutzte die Beispiele damit als Fragenvorrat statt als Bauplan für eine

theoriegeleitete Ableitung. Ein Hindernis zeigte sich bei der Dokumentation: Als NotebookLM den Fragebogen auf Wunsch als PDF ausgab, veränderte es einzelne Formulierungen. Maßgeblich für die Auswertung war daher stets die Antwort im Chat. Einzige Ausnahme ist die Einleitung aus Iteration 2, die nur im nicht mehr vorliegenden PDF stand. Ihre Mängel hält Nachricht 21 fest (Anhang B.3).

2.4 Iteration 1: Inhaltliche Führung im Dialog

Iteration 1 setzte an den inhaltlichen Mängeln an. Im Design wurde dazu die Wissensbasis um die Studien zu den Beispielfragebögen sowie um Theorie-, Krankenhaus- und Methodenquellen erweitert (Anhang B.1). NotebookLM wurde im Dialog schrittweise geführt: zunächst zur Theorie, dann zu den Konstrukten und schließlich zu den Fragen. Dabei sollte es keine Fragen aus den Beispielen übernehmen. Vorgaben zur Formulierung und zur Skala enthielt diese Iteration bewusst noch nicht, um die Wirkung der inhaltlichen Führung isoliert zu beobachten. In der Demonstration empfahl das Modell eine Synthese aus MAIRS-MS und Akzeptanzmodellen, darunter UTAUT und das integrierte Modell von Wichmann, Gesk, et al. (2024). Es leitete daraus zwölf statt der angekündigten elf Konstrukte ab und formulierte 36 Fragen auf einer siebenstufigen Skala. In der Evaluation zeigten sich gegenüber Iteration 0 deutliche Fortschritte bei Theoriebezug und Quellenarbeit: Alle Konstrukte waren definiert und mit Quellen belegt, Fragen aus fremden Kontexten tauchten kaum noch auf. Allerdings verbanden mehrere Konstrukte Dimensionen verschiedener Modelle, etwa „Förderliche Rahmenbedingungen & Verhaltenskontrolle“ (Z3). Zugleich traten neue Probleme auf. Das Modell vermischte KI-Readiness mit Akzeptanz, denn Konstrukte wie Nutzungsabsicht, Aufwandserwartung und Aufgabenpassung setzen ein konkretes System voraus. Das aus Patientensicht entwickelte Modell von Wichmann, Gesk, et al. (2024) wurde ohne Hinweis auf diese Perspektive übertragen. Den TRI 2.0 nutzte NotebookLM nur als Beleg für ein einzelnes Konstrukt, nicht als Modell mit seinen vier Dimensionen (Z1). Das Modell zitierte außerdem ein Werk nur über eine andere Quelle, ohne dies kenntlich zu machen (Z2). Zudem enthielten 18 von 36 Fragen weiterhin mehrere Aussagen oder wertende Begriffe wie „nahtlos“ (Z4). Viele Fragen unterstellten bereits eingeführte KI, etwa „die in unserem Krankenhaus eingesetzten KI-Anwendungen“ (Z5). Die inhaltliche Führung zeigte damit Wirkung, ließ aber zwei Lücken in der Steuerung offen. Erstens fehlte eine klare Abgrenzung von KI-Readiness und Akzeptanz, zu der auch der Befragungszeitpunkt vor der Einführung von KI gehört. Zweitens reicht inhaltliche Führung allein nicht für korrekt formulierte Fragen, dafür braucht es ausdrückliche Formulierungsregeln.

2.5 Iteration 2: Gezielte Korrekturen im Dialog

Iteration 2 setzte im selben Dialog an den beiden Lücken aus Iteration 1 an. Design, Demonstration und Evaluation wechselten sich hier in kurzen Schritten ab. Zunächst wurde NotebookLM auf die Vermischung mit Akzeptanz und auf den Befragungszeitpunkt vor der Einführung von KI hingewiesen und nach einem Modell für die allgemeine Haltung zu neuen Technologien gefragt. Daraufhin schlug es den TRI 2.0 vor, ließ aber die Dimension Vision der MAIRS-MS aus und führte die Dimension Unsicherheit doppelt auf. Zudem zitierte es das Technology Acceptance Model mit seiner Originalquelle, obwohl diese nicht im Notebook lag (Z2). Es folgten zwei weitere Hinweise. NotebookLM sollte die Dimensionen gewählter Modelle vollständig und jeweils nur einmal übernehmen und ausschließlich Quellen aus dem Notebook zitieren. Erst danach entstand ein Messmodell aus den vier Dimensionen des TRI 2.0 und den vier der MAIRS-MS, also genau der in Kapitel 2.2 festgelegte Maßstab (Z1, Z3). Auf Basis der Originalskalen formulierte das Modell anschließend 24 Fragen. Nach einer kritischen Prüfung enthielten sie keine Mehrfachaussagen mehr. Formulierungen wie „Stärken und Schwächen“ wurden allerdings teils durch Streichen statt durch Aufteilen bereinigt (Z4). Danach vereinfachte das Modell den Fragebogen für eine Pflegekraft ohne KI-Vorwissen und ergänzte Skala, Einleitung sowie Angaben zur Person. Dabei entstanden erneut Mehrfachaussagen wie „überprüfen und kritisch hinterfragen“: Zwölf von 24 Fragen bündelten wieder mehrere Aussagen (Z4). Außerdem enthielten mehrere Fragen Häufigkeitswörter wie „meist“, „oft“ oder „manchmal“, die nicht zu einer Zustimmungsskala passen. Eine Wissensfrage verriet bereits die Antwort („Mir ist klar, dass …“), eine Ethikfrage war sozial erwünscht (Z4). Die Namen der Konstrukte standen sichtbar über den Fragen. Die Skala war nun einheitlich fünfstufig, die Kategorien zur KI-Vorerfahrung überschnitten sich aber weiterhin (Z6). Zwei Beobachtungen prägen diese Iteration. Erstens kann jede Überarbeitung frühere Korrekturen zunichtemachen, weshalb die Prüfung der Formulierung am Ende stehen muss. Zweitens übernahm das Modell jeden Hinweis bereitwillig und lobte ihn ausdrücklich. Den Hinweis auf die Akzeptanzkonstrukte nannte es einen „zentralen und sehr wichtigen Punkt“, den Hinweis auf fehlende und doppelte Dimensionen eine „sehr präzise und methodisch wichtige Korrektur“ (Anhang B.3). Ob ein Hinweis fachlich zutraf, prüfte es dabei nicht erkennbar. Eigene Fehler wie die fehlende Dimension Vision behob es erst, nachdem die steuernde Person sie benannt hatte. Zuvor hatte es denselben Entwurf noch als vorteilhaften Ansatz dargestellt. Daraus ergibt sich die Gefahr, dass auch fehlerhafte Hinweise ungeprüft übernommen werden. Die Qualität hing damit wesentlich vom Fachwissen der steuernden Person ab. Dieses Wissen wurde deshalb in Iteration 3 in einem Masterprompt festgeschrieben.

2.6 Iteration 3: Masterprompt

2.6.1 Entstehung und Demonstration

Der Masterprompt sollte als einzige Anweisung ohne weitere Hinweise der steuernden Person auskommen. Im Design dieser Iteration erstellte NotebookLM den ersten Entwurf selbst aus dem Gesprächsverlauf und den bisherigen Befunden. Er bündelte die Regeln zuverlässig, schrieb jedoch TRI 2.0 und MAIRS-MS als Theorie fest vor. Zudem enthielt er fertige Antwortkategorien sowie Beispielfragen zum Thema und bezog die organisatorische Bereitschaft ein. NotebookLM fror damit die Ergebnisse dieses einen Falls ein, statt allgemeine, übertragbare Leitlinien zu formulieren. In drei Korrekturrunden wurden diese Punkte behoben, zwei kleinere Präzisierungen erfolgten von Hand. Die finale Fassung (Anhang A.1) stellt den Auftrag mit Messgegenstand, Zielgruppe und Zeitpunkt an den Anfang und lässt NotebookLM die Theorie selbst wählen. Außerdem regelt sie Quellen, Konstrukte, Formulierung, Skala, Rahmen und Ausgabe. Für die Demonstration musste der Masterprompt ohne Vorgeschichte laufen. Im bisherigen Dialog kannte NotebookLM den gesamten Verlauf und überarbeitete den Prompt zunächst, statt ihn auszuführen. Für die beiden finalen Durchläufe wurde deshalb jeweils ein neues Notebook mit derselben Wissensbasis angelegt. Da NotebookLM den vollständigen Prompt nicht in einer Nachricht annahm, wurde er in zwei Teilen übermittelt. Gewertet wurde stets die Antwort nach Teil 2. In beiden Durchläufen entstand ein Fragebogen mit Einleitung, Angaben zur Person und 24 Fragen zu acht Dimensionen auf einer einheitlichen fünfstufigen Skala. Hinzu kamen eine Modellbegründung, eine Konstrukttabelle und ein Prüfprotokoll (Anhang C).

2.6.2 Evaluation

Die abschließende Bewertung prüft die finalen Leitlinien nach demselben Schema wie die Iterationen zuvor (Kapitel 2.1). Tabelle 2 in Anhang D zeigt die Ergebnisse aller Iterationen, für Iteration 3 fasst sie beide Durchläufe zusammen. Für Z4 wurde zusätzlich gezählt, wie viele Fragen mehrere Aussagen oder wertende Begriffe enthielten. Die größten Fortschritte gab es beim Theoriebezug und bei der Formulierung der Fragen (Z1, Z4). Quellenarbeit und Antwortformat blieben dagegen ab Iteration 1 nur weitgehend erfüllt (Z2, Z6). Bei den Quellen unterlief dem Modell in jeder dieser Iterationen ein anderer Zitierfehler, bei den Antwortkategorien zur KI-Nutzung blieben Überschneidungen bis zuletzt bestehen. In beiden Durchläufen wählte NotebookLM ohne ausdrückliche Vorgabe den TRI 2.0 und die MAIRS-MS (Z1). Dabei begründete es, warum Akzeptanzmodelle hier nicht passen. Alle acht Dimensionen erfasste es mit je drei Fragen (Z3). Keine der jeweils 24 Fragen bündelte mehrere Aussagen oder vermischte Zustimmung mit Häufigkeit (Z4). Wissen und Nutzung von KI wurden

getrennt abgefragt (Z6), die Namen der Dimensionen tauchten im Fragebogen nicht auf. Der Kern der Leitlinien erwies sich damit als stabil, obwohl die Fragen in beiden Durchläufen unterschiedlich formuliert waren.

Zugleich zeigten beide Durchläufe dieselben vier Schwächen. Erstens unterliefen NotebookLM Fehler bei der Wiedergabe der Quellen (Z2). Es kennzeichnete die UTAUT als nur indirekt zitiert, obwohl die Originalquelle von Venkatesh et al. (2003) im Notebook lag. Außerdem stellte es die MAIRS-MS so dar, als sei sie für Beschäftigte im Gesundheitswesen entwickelt worden. Tatsächlich richtet sie sich an Medizinstudierende (Karaca et al., 2021). Zweitens war je eine Ethikfrage wie „Ich beachte ethische Grundsätze …“ so gestellt, dass fast alle zustimmen dürften (Z4). Drittens überschnitten sich die Antwortkategorien zur KI-Nutzung (Z6). Viertens versprach die Einleitung, dass keine Rückschlüsse auf Personen möglich seien. Gerade in kleinen Stationsteams können die erhobenen Angaben zur Person jedoch genau solche Rückschlüsse ermöglichen (Z5). Die Regeln zu sozial erwünschten Fragen, Antwortkategorien und Einleitung standen erst im zweiten Teil des geteilten Prompts. NotebookLM lieferte aber schon nach Teil 1 alle 24 Fragen (Anhang C.1 und C.2, jeweils Nachricht 2). In Durchlauf 2 übernahm es davon 18 wörtlich, darunter die sozial erwünschte Ethikfrage. Ob die Schwächen daher rühren, lässt sich mit zwei Durchläufen nicht belegen. Wenig belastbar war auch das Prüfprotokoll. Es nannte korrigierte Entwürfe, die im Chatverlauf nirgends vorkommen. Teils wiederholten diese fast wörtlich die Negativbeispiele des Prompts. Außerdem bescheinigte es jedes Mal, sozial erwünschte Fragen beseitigt zu haben. Dennoch blieb je eine solche Frage im Fragebogen (Anhang C.1 und C.2, Nachricht 4). In beiden Durchläufen erzeugten die Leitlinien einen theoretisch fundierten Fragebogen. Wie bei Jussupow et al. (2021) hängt die Qualität des Ergebnisses aber davon ab, dass ein Mensch die Ausgabe kritisch prüft. Ausgerechnet diese Prüfung unterbleibt umso eher, je stärker Nutzende der KI vertrauen (Lee et al., 2025). Gegen eine weitere Iteration sprach, dass drei der vier Schwächen trotz ausdrücklicher Regel im Prompt auftraten. Die vierte legt der Prompt mit der geforderten Anonymitätszusage sogar selbst nahe. Die vier wiederkehrenden Schwächen bilden deshalb eine kurze Prüfliste, die diese Kontrolle anleitet. Sie wird zusammen mit dem Masterprompt bereitgestellt (Anhang A.2).

2.7 Kommunikation

Die Leitlinien werden über diese Arbeit und ein GitHub-Projekt (https://github.com/niklash105-tech/Masterprompt-und-Pruefliste-Seminararbeit-Hochschule-Wismar-Haehnlein-Niklas) an Forschung und Praxis kommuniziert (Peffers et al., 2007). Das Projekt enthält den Masterprompt mit Prüfliste (Anhang A), das Iterationsprotokoll

(Anhang B), die Chatverläufe der finalen Durchläufe (Anhang C) und die Quellenliste der Wissensbasis. Das NotebookLM-Notebook selbst ist nicht öffentlich, da es urheberrechtlich geschützte Quellen enthält. Mit der Quellenliste kann die Wissensbasis jedoch nachgebaut werden. So lassen sich die Leitlinien nachvollziehen und erneut ausführen. Für andere Themen genügt es allerdings nicht, Messgegenstand, Zielgruppe und Zeitpunkt zu ändern. Auch themenspezifische Regeln, etwa zur Zielgruppe oder zur KI-Vorerfahrung, müssen angepasst werden.

3 Fazit

3.1 Beantwortung der Forschungsfrage

Die Iterationen beantworten die Forschungsfrage mit acht Leitlinien. L1 Den Auftrag präzise festlegen: Messgegenstand, Zielgruppe und Befragungszeitpunkt sowie die Abgrenzung zu verwandten Konstrukten wie Akzeptanz (Iterationen 1 bis 3). L2 Die Theoriewahl dem LLM überlassen, sie aber an die hinterlegten Quellen binden (Iterationen 1 bis 3). L3 Gewählte Theorien mit allen Dimensionen und ohne Dopplungen abbilden (Iteration 2). L4 Beispielfragebögen nur als Bauplan nutzen, nicht als Fragenvorrat (Iteration 0). L5 Formulierungsregeln vorgeben und ihre Prüfung ans Ende stellen (Iterationen 0 bis 2). L6 Ein einheitliches Antwortformat mit überschneidungsfreien Kategorien festlegen (Iterationen 0 und 2). L7 Eine nachvollziehbare Ausgabe mit Modellbegründung, Konstrukttabelle und Prüfprotokoll verlangen (Iteration 3). L8 Den Prompt ohne Vorgeschichte ausführen und das Ergebnis mit der Prüfliste kontrollieren (Iteration 3 und Evaluation). L1 bis L7 müssen im Prompt festgeschrieben sein, da NotebookLM im Dialog jeden Hinweis ungeprüft übernahm. So gestaltet, wählte NotebookLM in zwei unabhängigen Durchläufen ohne ausdrückliche Vorgabe eine passende Theorie und erzeugte einen weitgehend regelkonformen Fragebogen (Anhang D, Tabelle 2). Wiederkehrende Schwächen bei der Wiedergabe von Quellen, einer sozial erwünschten Frage, sich überschneidenden Antwortkategorien und der Anonymitätszusage zeigen jedoch, dass die Leitlinien eine abschließende Prüfung durch einen Menschen nicht ersetzen (Jussupow et al., 2021).

3.2 Limitationen und Ausblick

Die Evaluation erfolgte artifiziell und wurde nur von einer Person vorgenommen, die die Leitlinien auch selbst entwickelt hat. Diese Person bringt mehrjährige Berufserfahrung in der Pflege sowie methodisches Vorwissen aus dem Studium mit. Zudem nutzte sie ein weiteres Sprachmodell (Claude) als Sparringspartner und bereitete damit teils ihre Nachrichten an NotebookLM und ihre Bewertungen vor. Beides erleichterte fachlich treffende Hinweise im Dialog und dürfte die Zahl der nötigen Iterationen verringert haben. Zugleich schränkt das die Übertragbarkeit auf Anwendende ohne diese Voraussetzungen ein. Reale Befragte, kognitive Pretests und eine psychometrische Prüfung fehlen. Ob der Fragebogen Objektivität, Reliabilität und Validität tatsächlich erreicht, bleibt damit offen. Die sechs Ziele prüfen vor allem die Form der Fragen, nicht deren Inhaltsvalidität, also ob jede Frage ihr Konstrukt trifft (MacKenzie et al., 2011). So fragten in Durchlauf 1 sechs der zwölf MAIRS-MS-Fragen nach digitalen oder technischen Systemen statt nach KI. Zudem beruhen die Ergebnisse auf

zwei Durchläufen mit einem Werkzeug und einem Anwendungsfall, an dem die Leitlinien auch entwickelt wurden. Die Theoriewahl war durch die Wissensbasis vorstrukturiert. Neben Akzeptanzmodellen und Ansätzen zur Bereitschaft der Organisation enthielt das Notebook mit MAIRS-MS und TRI 2.0 nur zwei Instrumente zur individuellen Readiness. Deren Dimensionen umschreibt der Prompt mit „Wissen, Zutrauen, Einstellungen und Sorgen“ bereits. Auch die Aufteilung des Prompts in zwei Teile und künftige Versionen von NotebookLM können die Ergebnisse beeinflussen. Schließlich ist die Übertragung der für Medizinstudierende entwickelten MAIRS-MS auf Klinikpersonal inhaltlich naheliegend, aber nicht geprüft.

Literaturverzeichnis

Ang, C.-S., Ito, S., Bajaj, S., Chow, M., Cleland, J., & Heaversedge, J. (2026). The Scale for AI Literacy in Health Care Workers: Development and validation. Journal of Medical Internet Research, 28, e92373.
https://doi.org/10.2196/92373

Antweiler, D., Albiez, D., Bures, D., Hosters, B., Jovy-Klein, F., Nickel, K., Reibel, T., Schramm, J., Sander, J., Antons, D., & Diehl, A. (2024). Einsatz von KI-basierten Anwendungen durch Krankenhauspersonal: Aufgabenprofile und Qualifizierungsbedarfe. Bundesgesundheitsblatt – Gesundheitsforschung – Gesundheitsschutz, 67(1), 66–75.
https://doi.org/10.1007/s00103-023-03817-x

Antweiler, D., Hülden, D., Kugler, S., & Poncelet, A. (2026). Künstliche Intelligenz im Krankenhaus: Strategien und Voraussetzungen für eine erfolgreiche Implementierung [Whitepaper]. Fraunhofer IAIS.
https://www.iais.fraunhofer.de/de/publikationen/studien.html

Do Khac, L. T., Leyer, M., Wichmann, J., & Richter, A. (2025). Divisional perspectives on trust in generative AI: An empirical study of senior decision-makers. Enterprise Information Systems.
https://doi.org/10.1080/17517575.2025.2481557

Hernandez, I., & Nie, W. (2023). The AI-IP: Minimizing the guesswork of personality scale item development through artificial intelligence. Personnel Psychology, 76(4), 1011–1035.
https://doi.org/10.1111/peps.12543

Jussupow, E., Spohrer, K., Heinzl, A., & Gawlitza, J. (2021). Augmenting medical diagnosis decisions? An investigation into physicians' decision-making process with artificial intelligence. Information Systems Research, 32(3), 713–735. https://doi.org/10.1287/isre.2020.0980

Karaca, O., Çalışkan, S. A., & Demir, K. (2021). Medical artificial intelligence readiness scale for medical students (MAIRS-MS) – development, validity and reliability study. BMC Medical Education, 21, 112. https://doi.org/10.1186/s12909-021-02546-6

Lambert, S. I., Madi, M., Sopka, S., Lenes, A., Stange, H., Buszello, C.-P., & Stephan, A. (2023). An integrative review on the acceptance of artificial intelligence among healthcare professionals in hospitals. npj Digital Medicine, 6, 111. https://doi.org/10.1038/s41746-023-00852-5

Lee, H.-P., Sarkar, A., Tankelevitch, L., Drosos, I., Rintel, S., Banks, R., & Wilson, N. (2025). The impact of generative AI on critical thinking: Self-reported reductions in cognitive effort and confidence effects from a survey of knowledge workers. In Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems (S. 1–22). ACM. https://doi.org/10.1145/3706598.3713778

Lenzner, T., & Menold, N. (2015). Frageformulierung (Version 1.1; GESIS Survey Guidelines). GESIS – Leibniz-Institut für Sozialwissenschaften. https://doi.org/10.15465/gesis-sg_017

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. In Advances in Neural Information Processing Systems 33 (S. 9459–9474). https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html

Maassen, O., Fritsch, S., Palm, J., Deffge, S., Kunze, J., Marx, G., Riedel, M., Schuppert, A., & Bickenbach, J. (2021). Future medical artificial intelligence application requirements and expectations of physicians in German university hospitals: Web-based survey. Journal of Medical Internet Research, 23(3), e26646. https://doi.org/10.2196/26646

MacKenzie, S. B., Podsakoff, P. M., & Podsakoff, N. P. (2011). Construct measurement and validation procedures in MIS and behavioral research: Integrating new and existing techniques. MIS Quarterly, 35(2), 293–334. https://doi.org/10.2307/23044045

Ouyang, S., Zhang, J. M., Harman, M., & Wang, M. (2025). An empirical study of the non-determinism of ChatGPT in code generation. ACM Transactions on Software Engineering and Methodology, 34(2), 1–28.
https://doi.org/10.1145/3697010

Parasuraman, A., & Colby, C. L. (2015). An updated and streamlined technology readiness index: TRI 2.0. Journal of Service Research, 18(1), 59–74. https://doi.org/10.1177/1094670514539730

Peffers, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A design science research methodology for information systems research. Journal of Management Information Systems, 24(3), 45–77.
https://doi.org/10.2753/MIS0742-1222240302

Sommer, D., Schmidbauer, L., & Wahl, F. (2024). Nurses' perceptions, experience and knowledge regarding artificial intelligence: Results from a cross-sectional online survey in Germany. BMC Nursing, 23, 205.
https://doi.org/10.1186/s12912-024-01884-2

Susarla, A., Gopal, R., Thatcher, J. B., & Sarker, S. (2023). The Janus effect of generative AI: Charting the path for responsible conduct of scholarly activities in information systems. Information Systems Research, 34(2), 399–408. https://doi.org/10.1287/isre.2023.ed.v34.n2

Venable, J., Pries-Heje, J., & Baskerville, R. (2016). FEDS: A framework for evaluation in design science research. European Journal of Information Systems, 25(1), 77–89.
https://doi.org/10.1057/ejis.2014.36

Venkatesh, V., Morris, M. G., Davis, G. B., & Davis, F. D. (2003). User acceptance of information technology: Toward a unified view. MIS Quarterly, 27(3), 425–478. https://doi.org/10.2307/30036540

Weinert, L., Müller, J., Svensson, L., & Heinze, O. (2022). Perspective of information technology decision makers on factors influencing adoption and implementation of artificial intelligence technologies in 40 German hospitals: Descriptive analysis. JMIR Medical Informatics, 10(6), e34678.
https://doi.org/10.2196/34678

Wichmann, J., Gesk, T. S., & Leyer, M. (2024). Acceptance of AI in health care for short- and long-term treatments: Pilot development study of an integrated theoretical model. JMIR Formative Research, 8, e48600.
https://doi.org/10.2196/48600

Wichmann, J., Paetow, T., Leyer, M., Aweno, B., & Sandkuhl, K. (2024). Determining design criteria for indoor positioning system projects in hospitals: A design science approach. Digital Health, 10, 20552076241229148. https://doi.org/10.1177/20552076241229148

Anhang A

A.1 Masterprompt mit Prüfliste

NotebookLM nahm den Prompt nicht in einer Nachricht an. Er wurde deshalb in zwei Teilen übermittelt. Teil 1 begann mit „Ich gebe dir nun einen zwei geteilten Prompt: Nr 1.“, Teil 2 mit „Teil 2“. Der mit [sic] markierte Tippfehler stand nur in Durchlauf 1.

Teil 1

Du hast den Auftrag, einen wissenschaftlich fundierten, verständlichen und praxistauglichen Fragebogen zur Messung der individuellen KI-Readiness von Krankenhauspersonal zu entwickeln. Der Befragungszeitpunkt ist vor der Einführung von Künstlicher Intelligenz im Krankenhaus (Prä-Implementierung). Es geht ausschließlich um die persönliche, subjektive Bereitschaft der Beschäftigten (wie Wissen, Zutrauen, Einstellungen und Sorgen) und explizit nicht um organisatorische Rahmenbedingungen oder die Akzeptanz eines bereits konkreten, eingeführten KI-Systems. Schlage zu Beginn deiner Antwort selbstständig ein bis zwei theoretische Modelle aus den im Notebook bereitgestellten Quellen vor, die sich am besten für diese Prä-Implementierungsmessung eignen und begründe deine Auswahl kurz wissenschaftlich. Unterscheide dabei strikt zwischen allgemeinen Bereitschaftsmodellen (Readiness) und reinen Akzeptanzmodellen, die eine konkrete Systemnutzung voraussetzen. Sobald du die Modelle ausgewählt hast, musst du alle Dimensionen dieser Modelle vollständig und jeweils genau einmal im Fragebogen abbilden. Es dürfen keine Dimensionen ausgelassen und keine redundanten Konstrukte doppelt geführt werden. Verwende für Zitate und Belege ausschließlich die vorliegenden Notebook-Quellen. Werke, die in den Texten nur sekundär erwähnt werden, kennzeichnest du zwingend mit „zitiert nach [Quelle aus dem Notebook]“. Wenn die Quellen zu einem Aspekt keine Belege hergeben, schreibst du an der entsprechenden Stelle „In den Quellen nicht belegt“. Die Beispielfragebögen aus dem Datensatz dienen dir ausschließlich als Vorbild für Form und Struktur, Fragen daraus dürfen nicht übernommen werden. Fragen aus den theoretischen Originalskalen der gewählten Modelle dürfen hingegen als Grundlage genutzt und angepasst werden. Formuliere für jede gewählte Modell-Dimension mindestens drei Fragen. Achte darauf, dass alle Fragen sprachlich so einfach und klar gestaltet sind, dass sie auch von Pflegekräften oder Verwaltungsmitarbeitenden ohne Informatik- oder KI-Vorwissen problemlos verstanden werden. Fachjargon ist zu vermeiden oder durch Alltagssprache zu ersetzen. Formuliere alle Fragen in der Ich-Form aus Sicht der Beschäftigten. Keine Frage darf voraussetzen, dass KI im Krankenhaus bereits genutzt wird. Jede Frage darf strikt nur eine einzige

Aussage enthalten (Single-Statement-Regel). Wenn ein Aspekt zwei relevante Facetten enthält, erstellst du daraus zwei separate Fragen, anstatt einen wichtigen Teil ersatzlos zu streichen. Vermeide dabei Verdopplungen durch Bindewörter oder Aufzählungen. Falsch wäre beispielsweise: „Die neue Software hilft mir schnell und zuverlässig bei der Arbeit.“ Richtig sind zwei getrennte Fragen: „Die neue Software hilft mir schnell bei der Arbeit.“ und „Die neue Software hilft mir zuverlässig bei der Arbeit.“ Wörter, die eine Häufigkeit oder Intensität beschreiben, dürfen in den Fragen keinesfalls vorkommen. Begriffe wie „oft“, „manchmal“, „meist“, „gelegentlich“ oder „selten“ gehören auf eine Häufigkeitsskala und verfälschen Zustimmungsfragen. Falsch wäre: „Ich nutze manchmal Tabellenkalkulationsprogramme.“ Richtig ist: „Ich kann Tabellenkalkulationsprogramme bedienen.“

Teil 2

Achte auf absolute Neutralität und vermeide Suggestivfragen oder verdeckte Annahmen. Wissensfragen dürfen die Antwort nicht vorwegnehmen oder die Lösung verraten. Falsch wäre: „Mir ist klar, dass Passwort-Manager Daten verschlüsseln.“ Richtig ist: „Ich kann erklären, wie ein Passwort-Manager Daten schützt.“ Zudem dürfen vor den einzelnen Teilen des Fragebogens keine Erklärungstexte stehen, die Wissen vermitteln oder spätere Fragen vorwegnehmen. Vermeide Trivial-Fragen oder Aussagen zur sozialen Erwünschtheit, denen nahezu jeder Befragte unterschiedslos zustimmen würde. Falsch wäre: „Mir ist wichtig, dass bei der Arbeit keine Fehler passieren.“ Richtig ist eine messbare Einstellung oder Kompetenz. Die theoretischen Namen der Konstrukte und Dimensionen dienen nur der methodischen Zuordnung und dürfen für die Befragten im Fragebogen nicht sichtbar sein. Die Abschnitte tragen rein funktionalen [sic] Überschriften. Alle Inhaltsfragen nutzen durchgängig eine einheitliche, 5-stufige Likert-Skala mit exakt folgender Beschriftung: 1 = Trifft gar nicht zu, 2 = Trifft eher nicht zu, 3 = Teils / teils, 4 = Trifft eher zu, 5 = Trifft voll und ganz zu. Der Fragebogen beginnt mit einer kurzen, wertschätzenden Einleitung, die den Zweck der Befragung erklärt, Vertraulichkeit und anonymisierte Auswertung zusichert, betont, dass es keine richtigen oder falschen Antworten gibt und nur Aspekte ankündigt, die im Fragebogen auch tatsächlich vorkommen. Darauf folgt ein Teil für Angaben zur Person und Tätigkeit. Entwickle hierfür überschneidungsfreie, logische Antwortoptionen für Berufsgruppe, Berufserfahrung im Krankenhaus, Altersgruppe und KI-Vorerfahrung (mit sauberer Trennung von theoretischem Wissen und praktischer Nutzung). Achte darauf, wo eine freie Option wie „Sonstige“ sinnvoll ist und wo nicht. Gliederung deiner Gesamtausgabe: 1. Modellauswahl: Nennung und kurze wissenschaftliche

Begründung der gewählten Modelle aus den Quellen samt korrekter Zitierweise. 2. Konstrukttabelle: Eine übersichtliche Tabelle mit den Spalten „Konstrukt/Dimension“, „Definition“ und „Quelle“. 3. Fragebogen: Der vollständige, direkt einsetzbare Fragebogen mit Einleitung, Demografie und allen Inhaltsfragen. 4. Prüfprotokoll: Ein kurzes Protokoll deiner abschließenden Qualitätsprüfung, in dem du konkret aufführst, welche Fragen du vor der Endfassung noch einmal korrigiert hast (z. B. Bereinigung von Doppelformulierungen oder Entfernung von Häufigkeitswörtern).

A.2 Prüfliste für die abschließende Prüfung durch einen Menschen

Die Prüfliste beruht auf den vier Schwächen, die in beiden Durchläufen auftraten (Kapitel 2.6.2). Sie wird nach der Ausgabe des Modells abgearbeitet. Das Prüfprotokoll von NotebookLM ersetzt sie nicht.

Nr.	Prüffrage	Vorgehen bei Abweichung
1	Sind alle Quellen richtig gekennzeichnet und wiedergegeben? Liegt ein als „zitiert nach“ markiertes Werk vielleicht doch im Original im Notebook? Werden die Originalskalen richtig beschrieben, etwa ihre Zielgruppe?	Werke, die im Original vorliegen, direkt zitieren. „Zitiert nach“ nur für Werke verwenden, die ausschließlich in anderen Quellen erwähnt werden. Beschreibungen der Originalskalen an der Quelle prüfen und korrigieren.
2	Gibt es Fragen, denen fast alle Befragten zustimmen würden, etwa Bekenntnisse zu ethischen Grundsätzen?	Durch eine Frage nach Wissen oder Kompetenz ersetzen.
3	Schließen sich alle Antwortkategorien gegenseitig aus, vor allem bei der KI-Nutzung (privat, beruflich, beides)?	Kategorien so umbauen, dass jede Person genau eine wählen kann.
4	Hält die Einleitung, was sie zur Anonymität verspricht? Lassen die Angaben zur Person in kleinen Teams Rückschlüsse auf Einzelne zu?	Zusage anpassen oder Kategorien zusammenfassen.

Anhang B

B.1 Wissensbasis

Iteration	Inhalt des Notebooks
0	Datensatz mit fünf Beispielfragebögen
1 bis 3	Zusätzlich: Studien zu den fünf Beispielfragebögen; Theoriequellen: Karaca et al. (2021), Parasuraman & Colby (2015), Venkatesh et al. (2003), Wichmann, Gesk, et al. (2024); Quellen zum Krankenhauskontext: Antweiler et al. (2024), Antweiler et al. (2026), Jussupow et al. (2021), Lambert et al. (2023), Maassen et al. (2021), Sommer et al. (2024), Weinert et al. (2022); Methodenquelle: MacKenzie et al. (2011)
Durchläufe 1 und 2	Je ein neues Notebook mit derselben Wissensbasis wie in den Iterationen 1 bis 3

B.2 Iterationsprotokoll - Nachrichtenverlauf

Nachricht	Iteration	Eingabe der steuernden Person	Ergebnis
1 bis 2	0	„Erstelle einen Fragebogen zur Messung der KI-Readiness von Krankenhauspersonal“	6 Dimensionen, 15 Fragen, siebenstufige Skala; keine Theorie, keine Quellen
3 bis 4	0	Ausgabe als PDF	Einzelne Formulierungen im PDF verändert
5 bis 6	1	Frage nach geeigneter Theorie mit Begründung und Quellen	Empfehlung einer Synthese aus MAIRS-MS und Akzeptanzmodellen
7 bis 8	1	Frage nach Konstrukten mit Quellen	11 Konstrukte angekündigt, 12 geliefert
9 bis 10	1	Drei Fragen je Konstrukt, keine Übernahme aus den Beispielen	36 Fragen, siebenstufige Skala
11 bis 12	2	Hinweis auf Akzeptanzkonstrukte und Befragungszeitpunkt; Frage nach Modell für die allgemeine Haltung zu Technik	TRI 2.0 vorgeschlagen; Vision fehlt, Unsicherheit doppelt, Technology Acceptance Model mit Originalquelle zitiert
13 bis 14	2	Dimensionen vollständig und je einmal übernehmen; nur Quellen aus dem Notebook	Messmodell aus 8 Dimensionen

15 bis 16	2	Drei Fragen je Konstrukt auf Basis der Originalskalen	24 Fragen
17 bis 18	2	Kritische Prüfung der Fragen	Keine Mehrfachaussagen mehr, teils durch Streichen statt Aufteilen
19 bis 20	2	Vereinfachung für Pflegekraft ohne KI-Vorwissen; fünfstufige Skala, Einleitung, Angaben zur Person	12 von 24 Fragen wieder mit Mehrfachaussagen
21 bis 22	3	Auftrag zum Masterprompt mit Liste aller Mängel	Erster Entwurf mit fest vorgegebener Theorie und organisatorischer Bereitschaft
23 bis 28	3	Drei Korrekturrunden	Theoriewahl durch das Modell, keine fertigen Antwortkategorien und Beispielfragen zum Thema, Ausgabe mit Begründung, Tabelle und Prüfprotokoll
29 bis 34	3	Finaler Prompt mit Präzisierungen von Hand, in zwei Teilen eingegeben	Modell überarbeitete den Prompt, statt ihn auszuführen
35 bis 38	3	Ausführung im Entwicklungsnotebook	Wegen bekannter Vorgeschichte nicht gewertet

B.3 Vollständiger Chatverlauf des Entwicklungsnotebooks

Der Chatverlauf der Iterationen 0 bis 3 (Nachrichten 1 bis 38) liegt wegen seines Umfangs als externe Datei im Prüfungsordner vor: Anhang_B3_Chatverlauf_Entwicklung.docx. Zusätzlich ist er im GitHub-Projekt abrufbar. Die Datei ist kein technischer Export, sondern wurde von NotebookLM auf Anfrage als Word-Dokument erzeugt. Dabei gab NotebookLM den Verlauf nicht vollständig wortgetreu wieder. Im ersten Export fehlten Teile der Nachrichten 22, 24, 26, 28, 30 und 36. Ein zweiter Export enthielt diese Nachrichten vollständig, veränderte aber in den Nachrichten 11, 17, 19, 21, 23, 25 und 29 der steuernden Person Zeichensetzung und einzelne Formulierungen, obwohl eine wortgetreue Wiedergabe verlangt war. Die vorliegende Fassung wurde deshalb aus beiden Exporten zusammengeführt und an den abweichenden Stellen mit dem Verlauf im Notebook abgeglichen. Den Kasten mit dem Masterprompt am Anfang hat NotebookLM beim ersten Export eingefügt. Er zeigt die Fassung aus Nachricht 34, also vor zwei Korrekturen von Hand. Seine Überschrift und der Hinweis darunter wurden nachträglich ergänzt. Die in den Durchläufen verwendete Fassung steht in Anhang A.1.

Anhang C

C.1 Chatverläufe der finalen Durchläufe

Die beiden finalen Durchläufe aus Iteration 3 liegen wegen ihres Umfangs als externe Dateien im Prüfungsordner vor. Zusätzlich sind sie im GitHub-Projekt abrufbar.

C.1 Durchlauf 1 (03.10.2026): Anhang_C1_Chatverlauf_Durchlauf1.docx

C.2 Durchlauf 2 (03.10.2026): Anhang_C2_Chatverlauf_Durchlauf2.docx

Für jeden Durchlauf wurde ein neues Notebook mit derselben Wissensbasis angelegt (Anhang B.1). Der Masterprompt wurde in zwei Teilen übermittelt (Anhang A.1). Gewertet wurde jeweils die Antwort nach Teil 2 in Nachricht 4. Sie enthält Modellauswahl, Konstrukttabelle, Fragebogen und Prüfprotokoll. Die Verläufe hat NotebookLM auf Anfrage als Word-Datei exportiert (jeweils Nachricht 7).

Anhang D

D.1 Ziele und Anforderungen

Z1 Theoriebezug: Das LLM schlägt eine oder mehrere Theorien aus den Quellen vor, begründet die Wahl und leitet die Fragen daraus ab. Herleitung: Messinstrumente erfordern eine theoretisch fundierte Konstruktdefinition (MacKenzie et al., 2011).

Z2 Belegbare Quellen: Alle Aussagen stützen sich auf die hinterlegten Quellen und sind korrekt zitiert. Herleitung: LLMs können Inhalte erfinden (Susarla et al., 2023).

Z3 Definierte Konstrukte: Jedes Konstrukt wird definiert und mit mindestens drei Fragen gemessen. Die Dimensionen gewählter Modelle sind vollständig und ohne Dopplungen enthalten. Herleitung: Konstrukte sind eindeutig zu definieren (MacKenzie et al., 2011).

Z4 Korrekt formulierte Fragen: Jede Frage enthält nur eine Aussage und ist neutral und verständlich formuliert. Herleitung: Fragen mit doppelter Aussage sind zu teilen oder zu streichen (MacKenzie et al., 2011).

Z5 Zielgruppe und Kontext: Die Fragen richten sich in Ich-Form an Klinikpersonal und passen zum Befragungszeitpunkt vor der Einführung von KI. Einleitung und Angaben zur Person passen zur Befragungssituation. Herleitung: KI-Readiness betrifft Wissen, Fähigkeiten und Einstellungen des Personals (Karaca et al., 2021) und sollte vor der Einführung von KI bekannt sein (Antweiler et al., 2024).

Z6 Antwortformat: Alle Inhaltsfragen nutzen eine einheitlich beschriftete Skala. Die Antwortkategorien bei den Angaben zur Person überschneiden sich nicht. Herleitung: Nur einheitliche, eindeutige und überschneidungsfreie Antwortmöglichkeiten machen die Antworten vergleichbar (Lenzner & Menold, 2015).

D.2 Bewertungsstufen

Jedes Ziel wurde in eine von vier Stufen eingeordnet:

- erfüllt: Anforderung vollständig umgesetzt
- weitgehend: einzelne Abweichungen
- teilweise: deutliche Mängel
- nicht erfüllt: Anforderung nicht erkennbar umgesetzt

Für Z4 steht in Klammern die Anzahl der Fragen mit mehreren Aussagen oder wertenden Begriffen im Verhältnis zur Gesamtzahl. Als Mehrfachaussage zählt jede Frage, die zwei bewertbare Sachverhalte verbindet, etwa „schneller und einfacher“. Paarformeln wie „Kolleginnen und Kollegen“ zählen nicht.

Ziel	**Anforderungen an die Leitlinien**	**Begründung**
Z1 Theoriebezug	Das LLM schlägt eine oder mehrere Theorien vor, begründet die Wahl und leitet die Fragen daraus ab.	Messinstrumente erfordern eine theoretisch fundierte Konstruktdefinition (MacKenzie et al., 2011).
Z2 Belegbare Quellen	Alle Aussagen stützen sich auf die hinterlegten Quellen und sind überprüfbar.	LLMs können Inhalte erfinden (Susarla et al., 2023).
Z3 Definierte Konstrukte	Jedes Konstrukt wird definiert und mit mindestens drei Fragen gemessen. Die Dimensionen gewählter Modelle sind vollständig und ohne Dopplungen enthalten.	Konstrukte sind eindeutig zu definieren (MacKenzie et al., 2011).
Z4 Korrekt formulierte Fragen	Jede Frage enthält nur eine Aussage und ist neutral und verständlich formuliert.	Fragen mit doppelter Aussage sind zu teilen oder zu streichen (MacKenzie et al., 2011).
Z5 Zielgruppe und Kontext	Die Fragen richten sich in Ich-Form an Klinikpersonal und passen zum Befragungszeitpunkt vor der Einführung von KI. Einleitung und Angaben zur Person passen zur Befragungssituation.	KI-Readiness betrifft Wissen, Fähigkeiten und Einstellungen des Personals (Karaca et al., 2021).
Z6 Antwortformat	Alle Inhaltsfragen nutzen eine einheitlich beschriftete Skala. Die	Nur einheitliche, eindeutige und überschneidungsfreie

	Antwortkategorien bei den Angaben zur Person überschneiden sich nicht.	Antwortmöglichkeiten machen die Antworten vergleichbar (Lenzner & Menold, 2015).

Tab. 1: Ziele und Anforderungen an die Leitlinien

Ziel	Iteration 0	Iteration 1	Iteration 2	Iteration 3
Z1 Theoriebezug	nicht erfüllt	teilweise	erfüllt[1]	erfüllt
Z2 Belegbare Quellen	nicht erfüllt	weitgehend	weitgehend	weitgehend
Z3 Definierte Konstrukte	teilweise	teilweise	weitgehend	erfüllt
Z4 Korrekt formulierte Fragen	Nicht erfüllt (11/15)	teilweise (18/36)	teilweise (12/24)	weitgehend (0/24)[2]
Z5 Zielgruppe und Kontext	teilweise	teilweise	weitgehend[3]	weitgehend[3]
Z6 Antwortformat	teilweise	weitgehend	weitgehend	weitgehend

Tab. 2: Zielerreichung über alle Iterationen (eigene Darstellung)

[1] erst nach Hinweisen der steuernden Person

[2] keine Mehrfachaussagen, aber je eine sozial erwünschte Frage

[3] Die Einleitung sagte vollständige Anonymität zu, obwohl Angaben zur Person erhoben wurden (Iteration 2: Anhang B.3, Nachricht 21; Iteration 3: Anhang C, Nachricht 4)

Ehrenwörtliche Erklärung

In dieser Arbeit habe ich generative KI wie folgt eingesetzt:

- NotebookLM (Google, Stand Oktober 2026) ist Gegenstand der Untersuchung. Mit dieser KI habe ich die Leitlinien entwickelt und erprobt. Die Eingaben und Ausgaben sind in Anhang B und C dokumentiert.
- Claude (Anthropic) habe ich bei der Entwicklung der Leitlinien als Hilfsmittel genutzt. Einen Teil meiner Nachrichten an NotebookLM habe ich mit Claude vorformuliert (Nachrichten 11, 13 und 21 in Anhang B.3). Auch die Bewertung der Fragebögen habe ich teils mit Claude vorbereitet und Claude als Sparringspartner genutzt. Inhaltlich und Aussage stammen jedoch von mir.
- Beim Schreiben hat mich Claude bei Gliederung unterstützt.
- Abbildung 1 habe ich mit Claude Opus 5.5 nach eigenen inhaltlichen Vorgaben erstellt.

Die Verantwortung für Inhalt und Aussagen der Arbeit liegt bei mir.

Ich versichere hiermit ehrenwörtlich, dass ich meine vorliegende Seminararbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel - insbesondere keine im Quellenverzeichnis nicht benannten Internet-Quellen - benutzt habe.

Die Arbeit wurde vorher nicht in einem anderen Prüfungsverfahren eingereicht und die eingereichte schriftliche Fassung entspricht derjenigen auf dem elektronischen Speichermedium.

Wörtlich oder dem Sinn nach aus anderen Werken entnommene Stellen sind unter Angabe der Quellen kenntlich gemacht.



Hamburg 23.10.2026

Ort, Datum Unterschrift (Vor- und Nachname)